

Proposition de pistes de solution et étude de faisabilité de l'assistant IA

Flux simplifié dans ton environnement privé

Le Dialer Catarina gère l'appel et produit le flux audio brut (voix du client et de l'agent).

Ce flux est envoyé directement vers un module interne de transcription.

Comme il n'y a pas d'Internet libre, il faut utiliser un moteur installé en local (par exemple Whisper déployé sur vos serveurs).

Le flux audio est converti en texte en temps réel sans dépendre du cloud public.

Le texte transcrit est traité sera traité par le modèle IA hébergé dans le réseau privé.

Ce modèle détecte les informations clés (nom, besoin, objection, budget...) et génère des suggestions de réponse.

Tout se fait sans connexion externe, donc l'IA reste disponible même hors ligne.

Les résultats (infos client, suggestions, résumé) s'affichent directement sur l'écran de l'agent.

L'agent garde le contrôle de la conversation, l'IA ne parle jamais au client.

Solutions techniques possibles

Whisper local déployé sur serveur interne fera la transcription temps réel sans dépendance cloud.

Le moteur IA embarqué (LLM léger ou modèle spécialisé) hébergé dans le réseau privé fera l'analyse du texte et la génération de suggestions.

Pipeline interne : flux audio fait la transcription locale et l'IA analysera puis montrera cette analyse sur l'interface agent.

Option hybride : si une connexion sécurisée est possible, on utilisera Azure Speech ou Google Speech-to-Text via VPN, mais cela dépendra des règles de sécurité.

Faisabilité

Transcription locale : faisable avec GPU ou serveurs optimisés, mais nécessite ressources matérielles.

Analyse IA locale : faisable avec modèles réduits ou optimisés (quantization, distillation).

Interface agent : simple à développer (panneau latéral ou widget intégré à Catarina).

Amélioration continue : stockage des appels enregistrés et analyse batch en fin de journée.

Prérequis nécessaires

Serveurs internes avec GPU/CPU puissants pour temps réel.

Déploiement et maintenance d'un moteur de transcription local.

Définition claire des scripts commerciaux pour guider l'IA.

API ou connecteur entre Catarina et le module IA.

Stockage sécurisé pour les enregistrements.

Outils ou services IA envisageables

Transcription : Whisper (local), Azure Speech, Google Speech-to-Text.

Analyse conversationnelle : modèles LLM internes (Azure OpenAI déployé en privé, ou modèles open source comme LLaMA/Anthropic adaptés).

NLP pipeline : détection d'objections, extraction d'informations, scoring d'intérêt.

Possibilité de récupérer l'audio ou la transcription

Audio brut : fourni par Catarina.

Transcription : générée par moteur local ou service cloud sécurisé.

Texte transcrit : analysé en direct par l'IA pour suggestions.

Limites techniques éventuelles

Latence : risque si la transcription ou l'analyse est trop lente.

Ressources matérielles : besoin de GPU pour temps réel.

Pas d'Internet libre : limite la créativité et l'accès à des données externes.

Maintenance : mise à jour manuelle des modèles et scripts.

Charge cognitive : trop d'informations peut perturber l'agent.

Risques à anticiper

Confidentialité : gestion des données sensibles (RGPD).

Fiabilité transcription : erreurs peuvent fausser les suggestions.

Compatibilité : intégration avec Catarina doit être validée.

Scalabilité : performance à tester avec plusieurs agents simultanés.

Étapes recommandées pour une première version

Prototype transcription locale avec Whisper sur un serveur interne.

Extraction d'informations clés (nom, besoin, objection) en temps réel.

Suggestions simples basées sur script commercial.

Résumé automatique de fin d'appel.

Analyse post-appel des enregistrements pour améliorer scripts.

Tests pilotes avec un petit groupe d'agents.

Itérations pour améliorer précision et pertinence.